



UNIVERSIDAD ESTATAL PENÍNSULA DE SANTA ELENA

Ingeniería de Software

Sexto Semestre

VI Inteligencia de Negocios

ENTREGABLE 3

Pipeline de Datos y Calidad

Informe técnico-académico de implementación ETL

Título del Proyecto

Plataforma de Inteligencia de Negocios para el análisis de tendencias, adopción y evolución de agentes de Inteligencia Artificial en el dominio del desarrollo de software mediante integración de datos heterogéneos durante el período 2023–2026

Repositorio del Proyecto

<https://github.com/DevTorres404/ai-agents-adoption-observatory.git>

Autores

Damian Jesús Torres Cadena
Melanie Adriana Tomalá Merejildo
Jean Pierre Cedeño Andrade **Docente:**

Ing. Anthony Pachay

Período Académico

2026–1

Índice

1. Propósito del Entregable	2
2. Arquitectura ETL Implementada	2
3. Fuentes de Datos Implementadas	2
3.1. Parámetros Dinámicos de Extracción	3
4. Zona Raw / Bronze	3
5. Zona Staging / Silver	4
6. Framework de Calidad de Datos	4
7. Métricas Verificables	5
8. Evidencias Generadas	5
9. Conclusiones	6

1. Propósito del Entregable

El Entregable 3 constituye la evidencia de implementación del proyecto de Inteligencia de Negocios. A diferencia del Entregable 2, orientado al diseño arquitectónico y multi-dimensional, este informe documenta la ejecución del pipeline ETL, la persistencia de datos en la zona Raw/Bronze, la consolidación en la zona Staging/Silver y la aplicación de controles de calidad verificables antes de avanzar hacia el Data Warehouse.

El alcance del entregable comprende la extracción desde fuentes web, API pública y dataset estructurado; la conservación de los registros originales; la normalización hacia una estructura tabular analítica; y la generación de evidencias CSV y bitácoras persistentes que permiten auditar la trazabilidad del proceso.

2. Arquitectura ETL Implementada

La solución implementa una arquitectura tipo Medallion con dos capas operativas principales dentro del alcance de este entregable:

Capa	Implementación	Función dentro del E3
Raw / Bronze	Archivos JSON por fuente y tablas <code>raw.raw_files</code> , <code>raw.raw_records</code> en PostgreSQL	Conserva la información original de cada fuente sin transformarla indebidamente.
Staging / Silver	Tabla <code>staging.stg_actividad_agente</code> , reconstruida mediante scripts Python	Integra, limpia, normaliza y homologa los registros para dejarlos listos para el Data Warehouse.
Quality	Módulos <code>src/quality</code> y evidencias en <code>docs/evidencias</code>	Verifica completitud, duplicados, nulos, casting, homologación, trazabilidad y errores de ejecución.

Tabla 1: Capas técnicas implementadas en el Entregable 3

El script principal de orquestación es `src/scripts/run_pipeline.py`. La capa Staging unificada se reconstruye desde `src/staging/stg_build_unified.py`, lo que permite reproducir el flujo a partir de los registros conservados en Raw.

3. Fuentes de Datos Implementadas

El proyecto integra seis fuentes principales para observar actividad técnica, producción especializada, popularidad, innovación y percepción comunitaria sobre agentes de Inteligencia Artificial aplicados al desarrollo de software. La fuente propia UPSE queda provisionada para una fase posterior y no se presenta como fuente consolidada mientras no exista tabulación final.

Fuente	Método	Rol Analítico	Evidencia técnica esperada
Reddit	Web scraping	Comunidad	Publicaciones y menciones relacionadas con agentes de IA en comunidades de desarrolladores. Raw en <code>data/raw/scraping/reddit/</code> .
DEV Community	Web scraping / API pública	Producción técnica	Artículos, tutoriales y experiencias técnicas de desarrolladores. Raw en <code>data/raw/scraping/devto/</code> .
Hacker News	Web scraping	Innovación tecnológica	Discusiones y tendencias emergentes. Raw en <code>data/raw/scraping/hackernews/</code> .
Google Trends	Web scraping / pytrends	Popularidad	Interés relativo de búsqueda por agente y periodo. Raw en <code>data/raw/scraping/google_trends/</code> .
GitHub	API pública REST	Actividad técnica	Repositorios, estrellas, forks, issues y actividad asociada a agentes de IA. Raw en <code>data/raw/api/github/</code> .
AI Dev Dataset: AI Coding	Archivo estructurado Parquet	Catálogo maestro	Dataset estructurado convertido a Raw JSON analítico. Raw en <code>data/raw/archivos/catalogo/</code> .

Tabla 2: Fuentes de datos utilizadas en el Entregable 3

3.1. Parámetros Dinámicos de Extracción

Fuente	Script	Parámetros dinámicos o configurables
GitHub REST API	<code>src/extractors/github_api.py</code>	<code>queries</code> , <code>pages</code> , <code>per_page</code> , token opcional y rango temporal desde 2023.
Hacker News	<code>src/extractors/hackernews_scraper.py</code>	URL objetivo, límite de registros y metadatos de ejecución.
Dev.to	<code>src/extractors/devto_scraper.py</code>	Busquedas por términos de agentes, límite de artículos, filtro de relevancia y rango temporal desde 2023.
Reddit	<code>src/extractors/reddit_scraper.py</code>	Búsquedas técnicas, límite de posts, selectores Playwright y metadata temporal.
Google Trends	<code>src/extractors/trends_scraper.py</code>	Lista de keywords, region, timeframe 2023-01-012026-12-31 y manejo de rate limit.
AI Dev Dataset	<code>src/extractors/aidedev_catalog.py</code>	Rutas Parquet, descarga controlada, agentes homologados y filtro temporal 2023-2026.

Tabla 3: Matriz de parámetros de extracción

4. Zona Raw / Bronze

La zona Raw conserva los registros originales en archivos por fuente y en PostgreSQL usando campos JSONB. La convención cronológica definida para el entregable es:

`fFuente_YYYY-MM-DD.ext`

Ejemplos esperados de archivos Raw:

```
data/raw/api/github/github_2026-06-28.json
data/raw/scraping/devto/devto_2026-06-28.json
data/raw/scraping/hackernews/hackernews_2026-06-28.json
data/raw/scraping/reddit/reddit_2026-06-28.json
data/raw/scraping/google_trends/google_trends_2026-06-28.json
data/raw/archivos/catalogo/aidedev_2026-06-28.json
```

El inventario completo de Raw no debe calcularse solo con archivos de la última corrida, sino desde PostgreSQL. La evidencia correspondiente se exporta en:

- docs/evidencias/inventario_raw.csv
- docs/evidencias/inventario_raw_completo.csv

5. Zona Staging / Silver

La tabla de Staging consolidada es `staging.stg_actividad_agente_ia`. Su objetivo es convertir datos heterogéneos en una estructura tabular consistente para el modelo dimensional del Entregable 4.

Aspecto	Contrato documentado
Tabla física	23 columnas en PostgreSQL.
Columnas analíticas	21 columnas orientadas al análisis.
Columnas técnicas	id y fecha_carga.
Evidencia	docs/evidencias/staging_contract_columns.csv.

Tabla 4: Contrato actual de Staging

Las transformaciones principales implementadas son:

- Aplanamiento de estructuras JSON para obtener columnas analíticas uniformes.
- Normalización de fechas ISO y filtrado del período 2023–2026.
- Clasificación de agentes mediante reglas de expresiones regulares.
- Categorización estratégica según rol analítico de la fuente y tipo de señal.
- Deduplicación por clave compuesta.

La regla de deduplicación aplicada es:

`fuelle + plataforma + id_origen_registro + nombre_agente + fecha_evento`

Esta regla evita contar varias veces el mismo evento cuando aparece duplicado dentro de una fuente o por recargas controladas.

6. Framework de Calidad de Datos

El framework de calidad implementa los siete controles obligatorios del Entregable 3. Cada control genera evidencia verificable mediante CSV, logs o consultas sobre PostgreSQL.

Control	Implementación	Evidencia
Compleitud Raw/Staging	Comparación entre registros Raw y registros consolidados en Staging.	quality_summary.csv, quality_summary_sin_fuelle_propia.csv.
Duplicados reales	Conteo por clave compuesta de deduplicación.	dedup_report.csv.

Control	Implementación	Evidencia
Nulos críticos	Revisión de columnas obligatorias para análisis.	<code>nulls_matrix.csv</code> .
Formato y casting	Validación de fechas, numéricos y transformaciones.	<code>casting_report.csv</code> .
Homologación entre fuentes	Mapeo de nombres de agentes, plataformas y categorías.	<code>homologation_map.csv</code> .
Bitácora de errores	Registro persistente de fallos HTTP, rate limit y anomalías.	<code>logs/pipeline_run.log</code> , <code>logs/pipeline_errors.csv</code> .
Métricas finales	Resumen estadístico reproducible.	<code>staging_stats.csv</code> , <code>quality_issue_breakdown.csv</code> .

Tabla 5: Controles de calidad implementados

7. Métricas Verificables

Las métricas se reportan excluyendo la fuente propia, debido a que la encuesta UPSE se mantiene provisionada pero no tabulada como fuente consolidada.

Métrica	Valor verificado
Registros Raw sin <code>fuentes_propia</code>	120026
Registros Staging sin <code>fuentes_propia</code>	119760
Complejidad general sin <code>fuentes_propia</code>	99.78 %
Merma Raw/Staging sin <code>fuentes_propia</code>	0.22 %
Duplicados reales removidos	210
Nulos críticos	0

Tabla 6: Métricas finales respaldadas por evidencia CSV

Estas cifras deben contrastarse con los archivos de evidencia generados al finalizar la corrida del pipeline. Si una fuente externa falla por restricciones de red, cambios HTML o rate limit, el evento debe quedar documentado en logs y no debe presentarse como extracción exitosa de la última corrida.

8. Evidencias Generadas

Los archivos principales de auditoría técnica se encuentran en `docs/evidencias/`:

- `source_execution_evidence.csv`
- `inventario_raw.csv`
- `inventario_raw_completo.csv`
- `staging_stats.csv`
- `quality_summary.csv`
- `quality_summary_sin_fuentes_propia.csv`
- `quality_issue_breakdown.csv`

- `aidedev_agent_summary.csv`
- `dedup_report.csv`
- `nulls_matrix.csv`
- `casting_report.csv`
- `homologation_map.csv`
- `staging_contract_columns.csv`

9. Conclusiones

El Entregable 3 queda documentado como una implementación reproducible y defendible del pipeline de datos. La arquitectura Raw/Staging está separada, los extractores generan evidencia por fuente, la capa Raw conserva datos originales, Staging ofrece una estructura tabular preparada para el Data Warehouse y el framework de calidad produce archivos auditables.

La fuente propia UPSE debe mantenerse como provisionada hasta finalizar su tabulación. Por tanto, las métricas oficiales de este entregable deben reportarse sin incluirla como fuente consolidada. Con esta salvedad, el proyecto puede avanzar al Entregable 4 tomando `staging.stg_actividad_agente_ia` como base para construir el modelo estrella.