



UNIVERSIDAD ESTATAL PENÍNSULA DE SANTA ELENA

Ingeniería de Software

Sexto Semestre

VI Inteligencia de Negocios

ENTREGABLE 2

Arquitectura de Datos Técnica y Modelo Dimensional

Título del Proyecto

Plataforma de Inteligencia de Negocios para el análisis de tendencias, adopción y evolución de agentes de Inteligencia Artificial en el dominio del desarrollo de software mediante integración de datos heterogéneos durante el período 2023–2026

Autores

Damian Jesús Torres Cadena
Melanie Adriana Tomalá Merejildo
Jean Pierre Cedeño Andrade

Docente:

Ing: Anthony Pachay

Período Académico

2026–1

Índice

1. Arquitectura de Datos Técnica	2
2. Modelo Dimensional	4
2.1. Declaración de Granularidad	4
2.2. Matriz del Modelo de Hechos	4
3. Justificación de la Topología del Esquema	6
4. Diccionario de Datos y Trazabilidad	6
5. Mapeo Estructural de KPIs	9

1. Arquitectura de Datos Técnica

La arquitectura técnica del proyecto se estructura en capas para integrar fuentes heterogéneas relacionadas con agentes de Inteligencia Artificial aplicados al desarrollo de software. El flujo inicia con la extracción de datos desde APIs, técnicas de web scraping, archivos estructurados y encuesta académica; posteriormente, los datos pasan por una zona Raw, una zona Staging y finalmente se consolidan en un Data Warehouse dimensional para su explotación mediante dashboards.




Figura 1: Arquitectura técnica de datos para el análisis de agentes de Inteligencia Artificial

Capa	Tecnologías / mecanismos	Función dentro de la arquitectura
Orígenes de datos	GitHub API, Reddit, DEV Community, Hacker News, Google Trends, CSV/JSON, Encuesta UPSE	Proveer datos sobre actividad técnica, popularidad, menciones, producción técnica, innovación y adopción académica.
Extracción	Python, requests, pandas, BeautifulSoup, pytrends	Extraer datos desde APIs, scraping web, archivos estructurados y formularios exportados.
Zona Raw	Archivos JSON, CSV o Parquet	Conservar los datos originales sin transformación para trazabilidad histórica.
Zona Staging	PostgreSQL, esquema staging , scripts Python y SQL	Limpiar, validar, estandarizar nombres de agentes, homologar fuentes y preparar datos para el DW.
Data Warehouse	PostgreSQL, esquema dw , Star Schema	Almacenar información analítica mediante una tabla de hechos y dimensiones.
Capa BI	Dashboard principal y prototipo interactivo opcional	Visualizar KPIs de popularidad, adopción, actividad técnica, producción técnica e innovación mediante una capa de presentación analítica.

Tabla 1: Capas técnicas de la arquitectura de datos

2. Modelo Dimensional

2.1. Declaración de Granularidad

Cada fila dentro de la tabla de hechos **FactActividadAgenteIA** representará una medición atómica de actividad, popularidad, adopción o interacción asociada a un agente de Inteligencia Artificial, en una fecha específica, proveniente de una fuente identificable y vinculada a un ID de origen del registro.

La granularidad definida permite analizar la evolución temporal de cada agente de IA por fuente, plataforma y categoría, evitando un modelo OLTP transaccional y priorizando el análisis agregado mediante métricas cuantitativas.

2.2. Matriz del Modelo de Hechos

Campo Destino	Tipo SQL	Descripción Funcional	Rol Estructural
id_hecho	SERIAL / INT	Clave primaria surrogada auto-incremental de la tabla de hechos.	PK
id_tiempo	INT	Clave foránea hacia la dimensión de tiempo.	FK
id_agente	INT	Clave foránea hacia la dimensión de agentes de IA.	FK
id_fuente	INT	Clave foránea hacia la dimensión de fuentes de datos.	FK
id_plataforma	INT	Clave foránea hacia la dimensión de plataformas digitales.	FK
id_categoria	INT	Clave foránea hacia la dimensión de categorías analíticas.	FK
id_origen_registro	VARCHAR(120)	Identificador original del registro en la fuente de procedencia.	Degenerada
cantidad_menciones	INT	Número de menciones detectadas del agente en la fuente.	Métrica
cantidad_interacciones	INT	Total de interacciones asociadas al registro: comentarios, votos, reacciones o respuestas.	Métrica
score_popularidad	DECIMAL(10,2)	Valor normalizado de popularidad del agente según la fuente analizada.	Métrica
stars_github	INT	Número de estrellas obtenidas por repositorios relacionados con el agente.	Métrica
forks_github	INT	Número de forks en repositorios asociados al agente.	Métrica
issues_abiertos	INT	Número de issues abiertos en repositorios relacionados.	Métrica
releases	INT	Cantidad de versiones o releases publicados por período.	Métrica
indice_adopcion	DECIMAL(5,2)	Porcentaje normalizado de adopción del agente según encuesta o fuente estructurada.	Métrica
indice_innovacion	DECIMAL(5,2)	Indicador calculado para medir aparición, novedad o crecimiento del agente por período.	Métrica
sentimiento_promedio	DECIMAL(5,2)	Valor promedio de percepción textual asociado al agente, en escala de -1 a 1.	Métrica
fecha_carga	TIMESTAMP	Fecha y hora de carga del registro al Data Warehouse.	Auditoría

Tabla 2: Matriz del modelo de hechos

3. Justificación de la Topología del Esquema

Criterio Evaluativo	Star Schema (Estrella)	Snowflake (Copo de Nieve)	Galaxy Schema (Galaxia)
Rendimiento Joins	Alto	Medio	Alto
Redundancia	Alta	Baja	Media
Complejidad	Baja	Media	Alta
Facilidad para BI	Alta	Media	Media
Mantenimiento académico	Alto	Medio	Bajo
¿Aplica al caso?	Sí	No	No

Tabla 3: Comparación de topologías dimensionales

Se selecciona un **Star Schema** porque el proyecto requiere analizar métricas agregadas de popularidad, adopción, actividad técnica e innovación de agentes de IA con consultas simples y eficientes. Esta topología facilita la conexión con una capa de dashboard principal, reduce la complejidad del modelo y evita diseñar una base OLTP normalizada. El enfoque Snowflake no se prioriza porque aumentaría la cantidad de joins sin aportar un beneficio relevante para este hito. El enfoque Galaxy tampoco aplica, debido a que el modelo actual se centra en una tabla de hechos principal.

4. Diccionario de Datos y Trazabilidad

Tabla DW	Campo DW	Tipo	Regla / Valores	Atributo Staging	Transformación	Fuente Origen
DimTiempo	id_tiempo	INT	PK, formato AAAAMMDD	stg_fecha	Conversión de fecha a clave numérica.	Todas las fuentes
DimTiempo	fecha	DATE	Fecha válida	stg_fecha	Conversión a tipo DATE.	Todas las fuentes
DimTiempo	anio	SMALLINT	2023–2026	stg_fecha	Extracción del año.	Todas las fuentes
DimTiempo	trimestre	SMALLINT	1–4	stg_fecha	Cálculo del trimestre.	Todas las fuentes
DimTiempo	mes	SMALLINT	1–12	stg_fecha	Extracción del mes.	Todas las fuentes
DimTiempo	nombre_mes	VARCHAR(20)	Enero–Diciembre	stg_fecha	Conversión del número de mes a nombre.	Todas las fuentes
DimTiempo	semana	SMALLINT	1–53	stg_fecha	Cálculo de semana del año.	Todas las fuentes
DimFuente	id_fuente	INT	PK auto-incremental	stg_fuente	Generación de clave surrogate.	Todas las fuentes
DimFuente	nombre_fuente	VARCHAR(60)	GitHub, Reddit, DEV, Hacker News, Google Trends, CSV/JSON, Encuesta UPSE	stg_fuente	Estandarización del nombre de la fuente.	Todas las fuentes
DimFuente	tipo_fuente	VARCHAR(40)	API, Scraping, Archivo, Encuesta	stg_tipo_fuente	Clasificación del mecanismo de origen.	Todas las fuentes
DimFuente	mecanismo_extraccion	VARCHAR(80)	requests, BeautifulSoup, pytrends, carga CSV	stg_mecanismo	Registro del mecanismo de extracción utilizado.	Scripts Python
DimAgente	id_agente	INT	PK auto-incremental	stg_nombre_agente	Generación de clave surrogate.	Dataset CSV/JSON
DimAgente	nombre_agente	VARCHAR(80)	Nombre oficial del agente	stg_nombre_agente	Estandarización de variantes del nombre.	Dataset CSV/JSON, GitHub, comunidades
DimAgente	desarrollador	VARCHAR(100)	Organización o proveedor	stg_desarrollador	Normalización de nombre de empresa o comunidad.	Dataset CSV/JSON
DimAgente	modelo_base	VARCHAR(100)	GPT, Claude, Gemini, modelo propio u otro	stg_modelo_base	Homologación de modelo base.	Dataset CSV/JSON
DimAgente	categoria_agente	VARCHAR(80)	Asistente, editor IA, agente autónomo, herramienta QA	stg_categoria_agente	Clasificación por categoría funcional.	Dataset CSV/JSON
DimAgente	fecha_lanzamiento	DATE	Fecha válida o NULL	stg_fecha_lanzamiento	Conversión a tipo DATE.	Dataset CSV/JSON
DimPlataforma	id_plataforma	INT	PK auto-incremental	stg_plataforma	Generación de clave surrogate.	Todas las fuentes
DimPlataforma	nombre_plataforma	VARCHAR(80)	GitHub, Reddit, DEV Community, Hacker News, Google Trends, UPSE	stg_plataforma	Estandarización del nombre de plataforma.	Todas las fuentes
DimPlataforma	tipo_plataforma	VARCHAR(60)	Repositorio, comunidad, buscador, encuesta, archivo	stg_tipo_plataforma	Clasificación analítica de plataforma.	Todas las fuentes
DimCategoria	id_categoria	INT	PK auto-incremental	stg_categoria	Generación de clave surrogate.	Todas las fuentes
DimCategoria	nombre_categoria	VARCHAR(80)	Popularidad, adopción, actividad técnica, producción técnica, innovación	stg_categoria	Homologación de categoría analítica.	Todas las fuentes
DimCategoria	descripcion	VARCHAR(200)	Descripción funcional de la categoría	stg_categoria	Asignación de descripción según regla de negocio.	Diccionario interno
FactActividadAgenteIA	id_hecho	SERIAL / INT	PK auto-incremental	No aplica	Generación automática al insertar el registro.	DW
FactActividadAgenteIA	id_tiempo	INT	FK válida en DimTiempo	stg_fecha	Búsqueda de clave en DimTiempo.	Todas las fuentes
FactActividadAgenteIA	id_agente	INT	FK válida en DimAgente	stg_nombre_agente	Búsqueda de clave por nombre estandarizado del agente.	Todas las fuentes
FactActividadAgenteIA	id_fuente	INT	FK válida en DimFuente	stg_fuente	Búsqueda de clave por fuente homologada.	Todas las fuentes
FactActividadAgenteIA	id_plataforma	INT	FK válida en DimPlataforma	stg_plataforma	Búsqueda de clave por plataforma.	Todas las fuentes

Tabla DW	Campo DW	Tipo	Regla / Valores	Atributo Staging	Transformación	Fuente Origen
FactActividadAgenteIA	id_categoria	INT	FK válida en DimCategoria	stg_categoria	Clasificación según tipo de métrica y fuente.	Todas las fuentes
FactActividadAgenteIA	id_origen_registro	VARCHAR(120)	ID original, URL o hash	stg_id_origen	Conservación del identificador original del registro.	Todas las fuentes
FactActividadAgenteIA	cantidad_menciones	INT	Mayor o igual a 0	stg_menciones	Conteo de apariciones del agente por período y fuente.	Reddit, DEV, Hacker News, Trends
FactActividadAgenteIA	cantidad_interacciones	INT	Mayor o igual a 0	stg_interacciones	Suma de comentarios, votos, reacciones o respuestas disponibles.	Reddit, DEV, Hacker News
FactActividadAgenteIA	score_popularidad	DECIMAL(10,2)	0–100	stg_score_trends	Normalización del interés relativo de búsqueda.	Google Trends
FactActividadAgenteIA	stars_github	INT	Mayor o igual a 0	stg_stars	Conversión a entero y validación de nulos.	GitHub API
FactActividadAgenteIA	forks_github	INT	Mayor o igual a 0	stg_forks	Conversión a entero y validación de nulos.	GitHub API
FactActividadAgenteIA	issues_abiertos	INT	Mayor o igual a 0	stg_open_issues	Conversión a entero y validación de nulos.	GitHub API
FactActividadAgenteIA	releases	INT	Mayor o igual a 0	stg_releases	Conteo de releases por repositorio y período.	GitHub API
FactActividadAgenteIA	indice_adopcion	DECIMAL(5,2)	0–100	stg_uso_encuesta	Cálculo porcentual de usuarios que declaran uso del agente.	Encuesta UPSE
FactActividadAgenteIA	indice_innovacion	DECIMAL(5,2)	0–100	stg_novedad	Normalización de señales de aparición, lanzamiento o crecimiento.	Hacker News, GitHub, Dataset
FactActividadAgenteIA	sentimiento_promedio	DECIMAL(5,2)	-1 a 1	stg_texto	Análisis de percepción textual y promedio por agente/fuente.	Reddit, DEV, Hacker News
FactActividadAgenteIA	fecha_carga	TIMESTAMP	Fecha y hora del proceso ETL	stg_fecha_carga	Registro automático del momento de carga.	Scripts ETL

Tabla 4: Diccionario de datos y trazabilidad del Data Warehouse

5. Mapeo Estructural de KPIs

KPI del Hito E1	Campos DW utilizados	Fórmula estructural	Fuente principal
Índice de Popularidad	score_popularidad, id_agente, id_tiempo, id_fuente	Promedio o suma normalizada del score de búsqueda por agente y período.	Google Trends
Participación Comunitaria	cantidad_menciones, cantidad_interacciones, id_agente, id_plataforma	Menciones del agente / total de menciones del período.	Reddit
Actividad Open Source	stars_github, forks_github, issues_abiertos, releases	Stars + Forks + Issues + Releases.	GitHub API
Producción Técnica	cantidad_menciones, cantidad_interacciones, id_plataforma	Conteo de publicaciones técnicas asociadas al agente.	DEV Community
Índice de Innovación	indice_innovacion, cantidad_menciones, releases	Valor normalizado de señales de novedad o crecimiento por período.	Hacker News / GitHub
Nivel de Adopción Académica	indice_adopcion, id_agente, id_tiempo	Usuarios que utilizan agentes IA / total de encuestados.	Encuesta UPSE

Tabla 5: Mapeo de KPIs del Hito E1 hacia el modelo dimensional