



UNIVERSIDAD ESTATAL PENÍNSULA DE SANTA ELENA

Carrera de Ingeniería de Software

Sexto Semestre

VI Inteligencia de Negocios

PARTE B
REPORTE DE INVESTIGACIÓN

Documento técnico en formato de artículo científico

Título del artículo

**Observatorio de adopción de agentes de inteligencia
artificial en el desarrollo de software: arquitectura
Medallion, KPIs y evaluación crítica de validez**

Proyecto de BI

**Plataforma de Inteligencia de Negocios para el análisis de tendencias, adopción y
evolución de agentes de inteligencia artificial en el dominio del desarrollo de
software durante el período 2023-2026**

Enlaces del Proyecto

Producción: <https://bi.labtorres.me/>

Repositorio:

<https://github.com/DevTorres404/ai-agents-adoption-observatory>

Autores

**Damian Jesús Torres Cadena
Melanie Adriana Tomalá Merejildo
Jean Pierre Cedeño Andrade**

Docente

Ing. Anthony Pachay

Período académico

2026-1

La Libertad, Santa Elena – Ecuador
Julio de 2026

Índice

1. Introducción y justificación	3
1.1. Objetivo general	4
1.2. Objetivos específicos	4
1.3. Preguntas de investigación	4
2. Marco teórico	4
2.1. Agentes de IA aplicados al desarrollo de software	4
2.2. Inteligencia de negocios y modelado dimensional	5
2.3. Arquitectura Medallion y procesos ETL	5
2.4. Calidad, procedencia y reproducibilidad de datos	5
2.5. KPIs, validez de constructo y concentración de fuentes	6
3. Metodología e infraestructura	6
3.1. Diseño del estudio y alcance	6
3.2. Fuentes de datos	7
3.3. Proceso de extracción, transformación y carga	7
3.4. Modelo dimensional	8
3.5. Definición de métricas y pruebas de robustez	9
3.6. Infraestructura tecnológica	10
4. Análisis y KPIs obtenidos	10
4.1. Estado operativo del Data Warehouse	10
4.2. Corrección de identidad e idempotencia	11
4.3. Adopción por agente en el Gold corregido	12
4.4. Participación y concentración por fuente	12
4.5. Calidad de datos	13
4.6. Piloto de enriquecimiento semántico	13
5. Discusión crítica y límites	13
5.1. Aporte del sistema	14
5.2. Amenazas a la validez	14
5.2.1. Validez temporal	14
5.2.2. Duplicación entre instantáneas	14
5.2.3. Validez de constructo	14

5.2.4. Sesgo y concentración de fuentes	14
5.2.5. Encuesta y generalización	15
5.2.6. Extracción y clasificación	15
5.2.7. Enriquecimiento LLM	15
5.2.8. Reproducibilidad operativa	15
5.3. Ruta de corrección para publicación científica	15
6. Conclusiones	16
Bibliografía	17
A. Modelo lógico y reglas de cálculo	18
A.1. Relaciones del esquema estrella	18
A.2. Diccionario de KPIs	18
B. Diccionario de datos Staging/Silver	19
C. Diccionario resumido de la tabla de hechos Gold	21
D. Artefactos de reproducibilidad del repositorio	22

Resumen

Este estudio presenta el diseño, implementación y auditoría crítica de un observatorio de inteligencia de negocios orientado a medir señales de adopción de agentes de inteligencia artificial en el desarrollo de software entre 2023 y julio de 2026. Se integraron diez fuentes heterogéneas mediante una arquitectura Medallion con capas Raw, Staging y Gold, PostgreSQL 16, procesos ETL en Python, una API FastAPI y un tablero React. El corte reproducible contiene 399.900 registros Raw y 127.364 hechos Gold correspondientes a entidades de origen únicas, con 14 agentes, 910.231 menciones y 1.905.375 interacciones. La completitud Raw–Staging fue 31,85 %, se identificaron 264.211 candidatos duplicados y no se detectaron nulos críticos, claves foráneas inválidas ni métricas negativas. Codex concentró el 67,07 % de las observaciones y el catálogo AIDev el 89,22 % de la evidencia. Fuente, plataforma, tecnología y comunidad se modelaron como conceptos distintos mediante metadatos, reglas trazables y miembros explícitos no determinados. Se concluye que la plataforma es reproducible y funcional para BI descriptivo, aunque la concentración de fuentes, la heterogeneidad de señales y las fechas agregadas de AIDev impiden interpretar sus KPIs como una tasa poblacional o una estimación causal.

Palabras clave: inteligencia de negocios, agentes de IA, arquitectura Medallion, Data Warehouse, calidad de datos, adopción tecnológica, ingeniería de software.

1. Introducción y justificación

Los agentes de inteligencia artificial para programación han evolucionado desde asistentes de autocompletado hacia sistemas capaces de proponer cambios, ejecutar tareas y participar en flujos de desarrollo. El conjunto AIDev documenta esta transición mediante actividad real de agentes en GitHub y ofrece una base empírica para estudiar adopción, colaboración y calidad en ingeniería de software [1, 2]. A su vez, la evidencia experimental indica que un asistente de programación puede reducir el tiempo de una tarea controlada, aunque ese resultado no equivale automáticamente a productividad sostenida en proyectos reales [3, 4].

El problema de investigación surge porque la adopción de estas herramientas deja señales dispersas y semánticamente distintas: repositorios, pull requests, búsquedas, publicaciones, noticias, conversaciones comunitarias y respuestas de encuesta. Contar registros sin conservar su procedencia o sin distinguir su unidad de análisis puede convertir volumen de datos en una falsa apariencia de evidencia. Por ello, el proyecto desarrolla una plataforma de BI que integra fuentes heterogéneas, conserva Raw como evidencia, normaliza un contrato analítico, materializa un esquema dimensional y publica KPIs auditables.

La justificación científica es doble. Primero, el observatorio permite estudiar un fenómeno reciente con un proceso reproducible y trazable. Segundo, obliga a evaluar la validez de los indicadores: una mención, una estrella, un pull request o una respuesta de encuesta representan constructos diferentes y no deben tratarse como equivalentes directos de uso efectivo. Esta distinción es coherente con estudios longitudinales que advierten que la actividad observable y la productividad percibida pueden divergir [4].

1.1. Objetivo general

Diseñar y evaluar una plataforma de inteligencia de negocios capaz de integrar, depurar y analizar señales heterogéneas sobre adopción de agentes de IA en el desarrollo de software, determinando tanto sus principales KPIs como los límites metodológicos que condicionan su interpretación.

1.2. Objetivos específicos

1. Implementar un pipeline Medallion con trazabilidad desde Raw hasta Gold.
2. Construir un modelo dimensional y vistas SQL para adopción, actividad, popularidad, fuentes, plataformas y evolución temporal.
3. Verificar completitud, nulos, duplicados, integridad referencial y consistencia del grano analítico.
4. Comparar los KPIs operativos con una lectura robusta que elimine repeticiones entre instantáneas.
5. Identificar amenazas de validez y proponer una ruta de mejora para una futura publicación científica.

1.3. Preguntas de investigación

- **PI1:** ¿Qué nivel de actividad y adopción observable presentan los agentes de IA dentro de las fuentes integradas?
- **PI2:** ¿Qué agentes, fuentes y plataformas concentran la evidencia disponible?
- **PI3:** ¿En qué medida las reglas de integración, deduplicación y fecha alteran los KPIs resultantes?
- **PI4:** ¿Qué condiciones deben cumplirse para transformar el observatorio operativo en un estudio publicable y reproducible?

2. Marco teórico

2.1. Agentes de IA aplicados al desarrollo de software

Un agente de programación puede entenderse operacionalmente como una herramienta que, además de generar código, actúa sobre un entorno de desarrollo y produce artefactos verificables. AIDev caracteriza pull requests atribuidos a agentes en proyectos reales y muestra que el fenómeno ya puede estudiarse a escala de repositorios [2]. En este proyecto, la adopción no se equipara a una sola variable: se aproxima mediante actividad técnica, menciones, interacciones, popularidad, señales de encuesta y un índice normalizado por fuente.

La literatura también obliga a separar tres conceptos: *presencia* de la herramienta, *uso* durante una tarea y *impacto* sobre productividad o calidad. El experimento de Peng *et al.* encontró una reducción del 55,8% en el tiempo de una tarea controlada con Copilot [3]; en cambio, un estudio longitudinal posterior no halló cambios estadísticamente significativos en actividad de commits después de la adopción [4]. En consecuencia, los KPIs de este observatorio son descriptivos y no causales.


2.2. Inteligencia de negocios y modelado dimensional

La inteligencia de negocios transforma datos integrados en estructuras que facilitan análisis, comparación y toma de decisiones. El modelado dimensional organiza los hechos cuantitativos alrededor de dimensiones descriptivas; su diseño exige seleccionar el proceso, declarar el grano, identificar dimensiones y determinar hechos [5, 6].

El modelo del proyecto adopta un esquema estrella con una tabla de hechos de actividad y seis dimensiones: tiempo, agente, fuente, plataforma, tecnología y comunidad. El grano declarado es la última representación disponible de una entidad de origen para un agente, una fuente y una plataforma. La fecha describe la observación, pero no forma parte de su identidad estable. Las claves primarias, foráneas, restricciones de no negatividad y unicidad implementadas en PostgreSQL aportan integridad estructural [11].

2.3. Arquitectura Medallion y procesos ETL

La arquitectura Medallion organiza el ciclo de datos en capas que incrementan progresivamente su estructura y calidad: Bronze conserva datos crudos, Silver limpia y valida, y Gold presenta datos enriquecidos para análisis [7]. En el proyecto, estas capas se materializan como esquemas PostgreSQL y archivos de evidencia:



Esta separación permite reconstruir capas posteriores sin alterar la evidencia original. No obstante, la reproducibilidad depende de que las transformaciones sean deterministas y de que una misma entidad conserve una identidad estable entre ejecuciones.

2.4. Calidad, procedencia y reproducibilidad de datos

ISO/IEC 25012 define un modelo general para establecer requisitos y evaluar calidad de datos estructurados [8]. El proyecto operacionaliza este principio mediante completitud, nulos críticos, conversiones, duplicados, conflictos de clave e integridad referencial. La procedencia se conserva con `raw_file_id`, inventarios, hashes SHA-256, fechas de carga y bitácoras de ejecución.

Los principios FAIR recomiendan que datos, algoritmos y flujos sean localizables, accesibles, interoperables y reutilizables [9]. A su vez, W3C PROV ofrece un marco conceptual para

describir entidades, actividades y agentes involucrados en la generación de datos [10]. Aunque el repositorio contiene trazas útiles, una publicación científica requeriría versionar explícitamente cada instantánea analítica, sus parámetros y la consulta exacta que genera cada tabla del artículo.

2.5. KPIs, validez de constructo y concentración de fuentes

Un KPI es válido cuando su fórmula y unidad de análisis representan el constructo que se desea estudiar. En este proyecto, *score de adopción* es un indicador operacional derivado de cada fuente; no es una tasa poblacional de adopción. Para examinar la dependencia respecto de un origen se utiliza también un índice de concentración:

$$H = \sum_{s=1}^S p_s^2, \quad (1)$$

donde p_s es la proporción de observaciones atribuida a la fuente s . Valores próximos a uno indican que la evidencia está dominada por pocas fuentes. Este índice se emplea de forma descriptiva, sin trasladar umbrales regulatorios de concentración de mercado.

3. Metodología e infraestructura

3.1. Diseño del estudio y alcance

Se realizó un estudio observacional, retrospectivo, descriptivo y exploratorio apoyado en ingeniería de datos. La ventana configurada fue del 1 de enero de 2023 al 13 de julio de 2026; el rango efectivamente observado fue del 3 de enero de 2023 al 13 de julio de 2026. La fecha final corresponde al corte de auditoría y el mes de julio de 2026 es parcial. La unidad técnica de la tabla de hechos es una entidad de origen única asociada a agente, fuente y plataforma, descrita además por fecha, tecnología y comunidad.

No se realizó muestreo probabilístico de desarrolladores ni inferencia causal. Los resultados describen exclusivamente el corpus integrado por el pipeline.

3.2. Fuentes de datos

Fuente	Mecanismo	Señal principal	Riesgo dominante
AIDev	Parquet/Zenodo	Pull requests, repositorios y agentes	Sobrerrepresentación y repetición de instantáneas
GitHub	API REST	Repositorios, estrellas, forks e incidencias	Límite de búsqueda y ambigüedad de palabras clave
Google Trends	pytrends	Interés relativo de búsqueda	Rate limits y escala relativa
Stack Overflow	Stack Exchange API	Preguntas asociadas a términos de agentes	Cobertura y falsos positivos semánticos
arXiv	API pública	Publicaciones académicas	Mención no equivalente a adopción
Google News	RSS	Cobertura informativa	Duplicación editorial y ruido
Reddit	Playwright	Conversación comunitaria	Sesgo de plataforma y cambios HTML
Hacker News	Extracción web	Puntos y comentarios	Muestra pequeña
Dev.to	API/extracción	Artículos y reacciones	Variación de estructura y relevancia
Encuesta UPSE	Google Forms/JSON	Adopción declarada	Muestra de conveniencia reducida

Tabla 1: Fuentes y naturaleza de las señales integradas.

El dataset principal AIDev corresponde a la versión 2 publicada en Zenodo por Li, Zhang y Hassan [1]. El repositorio descarga y transforma los archivos Parquet a JSON analítico sin modificar los archivos fuente. Para Stack Overflow se utiliza la API Stack Exchange v2.3 y su mecanismo de búsqueda documentado [12].

3.3. Proceso de extracción, transformación y carga

El procedimiento auditado consta de seis fases:

1. **Extracción:** ejecución independiente por fuente, captura de estado, cantidad, código HTTP, ruta y observaciones.
2. **Raw/Bronze:** persistencia en JSON y en `raw.raw_files/raw.raw_records` con hash y metadatos.
3. **Normalización:** homologación de columnas, conversiones numéricas, limpieza de caracteres y tipado de fechas.
4. **Homologación:** clasificación por expresiones regulares de 14 agentes autorizados y exclusión de registros no identificados.

5. **Calidad y Silver:** deduplicación, matrices de nulos, casting, reglas de categorías y exportación de evidencias CSV.
6. **Gold y servicio:** carga de dimensiones/hechos, siete vistas KPI, API REST y dashboard interactivo.

Como se muestra en la Figura 1, el observatorio integra las fuentes heterogéneas mediante las capas Raw/Bronze, Staging/Silver y Gold/Data Warehouse, antes de publicar los resultados mediante FastAPI y el dashboard React.




Figura 1: Arquitectura lógica y pipeline Medallion del Observatorio de Adopción de Agentes de IA.

Fuente: Elaboración propia.

Para fuentes no estructuradas existe un enriquecimiento opcional con Llama 3.2 mediante Ollama. El modelo opera con temperatura cero, semilla 42, vocabularios cerrados y umbral de confianza de 0,85. Después se ejecuta una capa determinista: primero consume metadatos estructurados, luego reglas contextuales y de agente, y finalmente asigna un miembro explícito “No determinada” cuando no existe evidencia. En este contrato, *fuentes* es el origen de extracción; *plataforma* es el entorno de ejecución o integración; *tecnología* identifica lenguajes, frameworks, protocolos o infraestructura; y *comunidad* representa propietarios, organizaciones o espacios sociales, académicos y editoriales.

3.4. Modelo dimensional

El Data Warehouse implementa el proceso de actividad de agentes con la siguiente estructura:

Objeto	Tipo	Propósito	Filas
gold.dim_tiempo	Dimensión	Fecha, año, semestre, trimestre, mes, semana y día	955
gold.dim_agente	Dimensión	Identidad, proveedor, tipo y categoría del agente	14
gold.dim_fuente	Dimensión	Origen, tipo, categoría y condición de fuente propia	10
gold.dim_plataforma	Dimensión	Entorno de ejecución/integración, tipo y ecosistema	12
gold.dim_tecnologia	Dimensión	Tecnología, categoría, dominio y tipo de señal	42
gold.dim_comunidad	Dimensión	Propietario o espacio, tipo, plataforma y región	91.158
gold.fact_actividad_agente_ia	Hechos	Métricas y claves de procedencia	127.364

Tabla 2: Modelo dimensional y conteos del corte auditado.

3.5. Definición de métricas y pruebas de robustez

La completitud se calculó como:

$$C = \frac{N_{Staging}}{N_{Raw}} \times 100, \quad M = 100 - C, \quad (2)$$

donde C es completitud y M merma. La participación de una fuente o agente se define como:

$$P_g = \frac{N_g}{\sum_j N_j} \times 100. \quad (3)$$

El *score de actividad* implementado en SQL es:

$$S_{act} = I + Stars + Forks + Issues + Releases, \quad (4)$$

donde I corresponde a interacciones. El score de comunidad suma menciones e interacciones únicamente para Reddit, Hacker News, Dev.to o registros clasificados como comunidad.

Para impedir repetición entre cargas se definió una clave estable independiente de la fecha:

$$K_e = (fuente, plataforma, agente, id_origen), \quad F = \frac{N_{Gold}}{N_{K_e}}, \quad (5)$$

donde F es el control de idempotencia por instantáneas repetidas. El ETL ordena versiones por fecha y `raw_file_id`, conserva determinísticamente la más reciente y aplica la misma unicidad en Staging y Gold. En el corte final, $N_{Gold} = N_{K_e} = 127,364$ y $F = 1,000$.

3.6. Infraestructura tecnológica

Capa	Tecnología	Función
Orquestación	Docker Compose	Despliegue de PostgreSQL, ETL, API y frontend
Datos	PostgreSQL 16	Esquemas Raw, Staging, Audit y Gold
ETL	Python, pandas, SQLAlchemy	Extracción, normalización, calidad y carga
Extracción	requests, Playwright, pytrends	APIs, RSS y fuentes web
Semántica	Ollama/Llama 3.2	Enriquecimiento opcional de texto no estructurado
Backend	FastAPI, asynpg, Uvicorn	Endpoints asíncronos de KPIs y filtros
Frontend	React, Vite, Recharts	Dashboard, gráficos, filtros y caché cliente
Publicación	Nginx, Cloudflare Tunnel	Servicio web y proxy hacia la API

Tabla 3: Infraestructura del observatorio.

4. Análisis y KPIs obtenidos

4.1. Estado operativo del Data Warehouse

La auditoría directa de PostgreSQL del 13 de julio de 2026 registró 399.900 filas Raw, 127.364 filas Staging y 127.364 hechos Gold. Las seis claves foráneas de la tabla de hechos resultaron válidas, no se detectaron métricas negativas ni duplicados bajo la clave estable y las siete vistas KPI devolvieron resultados. La igualdad Staging–Gold confirma que la materialización dimensional no perdió observaciones aptas.

KPI operativo	Resultado	Interpretación permitida
Hechos Gold	127.364	Entidades de origen únicas materializadas por el DW
Agentes / fuentes / plataformas	14 / 10 / 12	Cobertura nominal del modelo
Tecnologías / comunidades	42 / 91.158	Tecnologías y propietarios/espacios identificados
Menciones	910.231	Suma de la variable homologada; depende de la fuente
Interacciones	1.905.375	Suma de señales de interacción heterogéneas
Score de adopción total	9.966,14	Indicador operacional acumulado
Score de adopción promedio	0,0782	Promedio por hecho; no es porcentaje poblacional
Período Gold	2023-01-03 a 2026-07-13	Rango observado, con julio de 2026 incompleto

Tabla 4: Resumen operacional del Gold activo.

4.2. Corrección de identidad e idempotencia

Un corte histórico anterior contenía 356.945 hechos porque varias instantáneas de una misma entidad podían sobrevivir cuando la fecha participaba en la identidad. La corrección incorporó el identificador estable de origen, retiró la fecha de la clave de deduplicación, conservó la versión más reciente y alineó las restricciones SQL. El Gold vigente contiene 127.364 entidades y una segunda agrupación por K_e devuelve exactamente 127.364; por tanto, $F = 1,000$. La comparación siguiente documenta el efecto de la corrección, no dos lecturas coexistentes del DW actual.

Métrica	Corte histórico	Gold corregido	Razón	Efecto
Observaciones	356.945	127.364	2,803	Eliminación de instantáneas repetidas
Menciones	2.714.357	910.231	2,982	Corrección de acumulación histórica
Interacciones	5.485.179	1.905.375	2,879	Corrección de acumulación histórica
Adopción total	29.958,79	9.966,14	3,006	Una representación por entidad
Adopción promedio	0,0839	0,0782	1,072	Menor sensibilidad que los totales

Tabla 5: Efecto documentado de la corrección de identidad sobre los KPIs.

El corte histórico se conserva únicamente como evidencia de auditoría. Toda consulta, API y visualización vigente utiliza el Gold corregido. Los promedios continúan afectados por la

mezcla de escalas entre fuentes, aunque ya no por repetición de instantáneas.

4.3. Adopción por agente en el Gold corregido

Agente	Observaciones	Part.	Menciones	Interacciones	Adopción total
Codex	85.424	67,07 %	812.655	1.623.787	9.007,68
GitHub Copilot	16.383	12,86 %	52.516	105.025	544,19
Cursor	15.069	11,83 %	35.140	116.674	351,68
Claude Code	3.991	3,13 %	6.943	50.561	61,43
AWS Kiro	989	0,78 %	619	239	0,00
Aider	739	0,58 %	372	2.226	0,05
Cline	717	0,56 %	354	3.985	0,06
Resto de agentes	4.052	3,18 %	1.632	2.878	1,05

Tabla 6: Principales agentes en el Gold corregido.

Codex lidera el corpus con 67,07 % de las observaciones y 90,38 % del score de adopción total. Este hallazgo describe la composición del corpus; no demuestra que dos tercios de la población de desarrolladores use Codex.

4.4. Participación y concentración por fuente

Fuente	Observaciones	Participación	Menciones	Interacciones	Adopción
Catálogo AIDev	113.633	89,22 %	900.698	1.784.645	9.958,14
GitHub	6.299	4,95 %	6.299	118.375	0,00
Google Trends	5.180	4,07 %	0	0	0,00
Stack Overflow	812	0,64 %	1.815	1.808	0,00
Google News	743	0,58 %	743	0	0,00
arXiv	466	0,37 %	466	0	0,00
Reddit	199	0,16 %	199	0	0,00
Dev.to	23	0,02 %	3	3	0,00
Encuesta UPSE	8	0,01 %	8	0	8,00
Hacker News	1	<0,01 %	0	544	0,00

Tabla 7: Participación y métricas por fuente en el Gold corregido.

El índice de concentración fue $H = 0,8002$ (8.002 sobre una escala de 10.000), lo que confirma una dependencia muy alta del catálogo AIDev. La diversidad nominal de diez fuentes no implica equilibrio efectivo entre ellas.

4.5. Calidad de datos

Control	Resultado	Lectura crítica
Raw procesado	399.900	Universo persistido al corte
Staging materializado	127.364	Base reproducible usada por el Gold actual
Compleitud	31,85 %	Relación Staging/Raw
Merma	68,15 %	Diferencia Raw–Staging; las causas pueden solaparse
Candidatos duplicados	264.211	Repeticiones detectadas por la clave estable
Nulos críticos removidos	0	Cumplimiento del contrato crítico
Errores de casting	0	Conversión satisfactoria en campos auditados
Duplicados en clave estable Gold	0	Identidad independiente de fecha y clasificación
Claves foráneas inválidas	0	Integridad referencial satisfactoria

Tabla 8: Indicadores de calidad del corte 2026-07-13.

La diferencia Raw–Staging es 272.536 registros. Los 264.211 candidatos duplicados se calculan sobre el candidato normalizado antes de todas las exclusiones, por lo que no deben sumarse mecánicamente con ruido semántico u otras causas. El control final sí es directo: Staging y Gold contienen 127.364 filas y la clave estable no presenta duplicados.

4.6. Piloto de enriquecimiento semántico

El piloto LLM procesó 50 registros estratificados de cinco fuentes no estructuradas. Todos produjeron JSON válido, 40 registros (80 %) superaron simultáneamente el umbral de confianza 0,85 y la presencia de evidencia, y el tiempo promedio fue 5,89 segundos por registro. Estos valores prueban conformidad de salida, no exactitud semántica: no existe un conjunto etiquetado por humanos para estimar precisión, exhaustividad o acuerdo interevaluador.

En el corte completo, plataforma se obtuvo por metadatos estructurados en 375 filas (0,29 %), regla contextual en 5.414 (4,25 %) y regla de agente en 20.839 (16,36 %); 100.736 filas (79,09 %) permanecieron como “No determinada”. Tecnología se obtuvo por metadatos en 84.461 filas (66,31 %), por contexto en 4.738 (3,72 %) y quedó no determinada en 38.165 (29,97 %). Esta cobertura explícita evita presentar inferencias sin evidencia como datos observados.

5. Discusión crítica y límites

5.1. Aporte del sistema

El proyecto demuestra una integración técnica completa: múltiples extractores, persistencia Raw, un contrato Silver, auditoría, modelo estrella, vistas KPI, API asíncrona y dashboard. La arquitectura es coherente con el patrón Medallion y con la separación entre preparación y consumo analítico [7]. Además, el uso de claves foráneas, restricciones y vistas SQL favorece consistencia e inspección independiente [11].

La principal contribución no es afirmar una tasa universal de adopción, sino ofrecer un mecanismo auditable para estudiar señales de agentes de IA y mostrar cómo las decisiones del pipeline alteran la interpretación. Esta conclusión es especialmente relevante porque la literatura evidencia que actividad, percepción y productividad no son sinónimos [3, 4].

5.2. Amenazas a la validez

5.2.1. Validez temporal

El ETL preserva la fecha observada por la fuente; para AIDev utiliza `last_activity` y, si falta una fecha, emplea la fecha inmutable de carga del archivo Raw con `is_imputed_date=true`. En el Gold, 120.421 hechos (94,55 %) conservan fecha de fuente y 6.943 (5,45 %) usan ese sustituto trazable. La transformación es reproducible, pero `last_activity` resume el último momento de un agregado agente-repositorio y no cada evento individual. Por ello, las tendencias describen fechas de última actividad y no una incidencia mensual de adopción.

5.2.2. Duplicación entre instantáneas

La identidad Silver excluye `fecha_evento` y las clasificaciones semánticas. Ante varias instantáneas, el ETL ordena por fecha y `raw_file_id` y conserva la versión más reciente; PostgreSQL aplica la misma unicidad. El control $F = 1,000$ confirma ausencia de repeticiones en el corte actual. La contrapartida es que el DW representa estado vigente, no la evolución entre instantáneas; un análisis de snapshots requeriría una dimensión separada y hechos periódicos no acumulativos.

5.2.3. Validez de constructo

Las métricas combinan señales de naturaleza distinta. Por ejemplo, en AIDev una observación resume actividad por agente y repositorio, en GitHub una fila representa un repositorio, en Google Trends un valor relativo de búsqueda y en la encuesta una declaración individual. La suma transversal es útil como monitor operativo, pero no constituye una escala psicométrica ni una tasa poblacional validada.

5.2.4. Sesgo y concentración de fuentes

Después de la deduplicación, AIDev aún representa 89,22 % del corpus y el índice H es 0,8002. Por ello, el ranking reproduce principalmente la composición y ontología del

dataset dominante. Las fuentes comunitarias, académicas y de búsqueda funcionan como triangulación secundaria y no como estratos comparables.

5.2.5. Encuesta y generalización

El archivo fuente contiene 12 respuestas, pero solo 8 registros con agente autorizado aparecen como entidades únicas en Gold. Las cargas históricas ya no multiplican los hechos. La muestra es de conveniencia, pequeña y localizada en UPSE. No permite estimar prevalencia con margen de error conocido ni generalizar a la población de desarrolladores.

5.2.6. Extracción y clasificación

Las APIs y páginas pueden imponer límites, bloqueos o cambios de estructura. La búsqueda por términos como *Cursor*, *Codex* o *Copilot* puede recuperar homónimos. La exclusión de *Otro Agente IA* aumenta precisión aparente, pero reduce cobertura y puede introducir sesgo de catálogo cerrado.

5.2.7. Enriquecimiento LLM

La confianza es declarada por el propio modelo y no está calibrada contra verdad de referencia. El piloto no mide exactitud. El caché utiliza un hash MD5 determinista del texto, pero la reproducción externa también exige fijar la versión o digest del modelo Ollama y conservar el caché. Los campos LLM y las reglas contextuales deben tratarse como anotaciones auxiliares hasta realizar validación humana ciega y reportar métricas de acuerdo. Además, 79,09 % de las plataformas y 29,97 % de las tecnologías permanecen explícitamente no determinadas; esta ausencia es preferible a reciclar la fuente o la categoría.

La dimensión comunidad alcanza 91.158 miembros porque, según la fuente, conserva propietarios de repositorios, organizaciones, subreddits, medios o espacios académicos. Esta cardinalidad es coherente con el contrato implementado, pero no debe interpretarse como 91.158 comunidades sociales independientes; para ciertos análisis podría convenir modelar el propietario del repositorio como una dimensión separada.

5.2.8. Reproducibilidad operativa

Durante la auditoría final se registraron 127.364 filas tanto en Staging como en Gold, reconstruidas desde 399.900 registros Raw. Los archivos Raw conservan hash SHA-256, las fechas imputadas proceden de metadatos inmutables y 12 pruebas automatizadas cubren fechas, deduplicación y dimensiones semánticas. Persisten requisitos para reproducción externa: publicar un manifiesto del snapshot, el commit de Git, parámetros, digest del modelo local y consultas exactas de cada resultado.

5.3. Ruta de corrección para publicación científica

1. **[Completado]** Usar el identificador estable `agent:repo_id` de AIDev como `id_origen_registro`; no calcularlo desde toda la fila.

2. **[Completado]** Usar `last_activity` de AIDev, con `first_activity` como respaldo. Si una fuente no aporta fecha, usar la carga Raw inmutable y registrar `is_imputed_date=true`; nunca depender del día de ejecución.
3. **[Completado]** Separar *entidad observada* de *instantánea de extracción*. La instantánea debe ser una dimensión de auditoría, no parte de la identidad analítica.
4. **[Completado]** Diferenciar fuente, plataforma, tecnología y comunidad mediante metadatos, reglas trazables, método de derivación y miembros no determinados.
5. **[Completado]** Recalcular Staging y Gold desde Raw, exigir igualdad de filas, validar integridad y ejecutar pruebas automatizadas de fechas, identidad y semántica.
6. Publicar un manifiesto externo del snapshot con hashes, parámetros, commit de Git, digest del modelo y consulta de reproducción.
7. Definir KPIs por estrato de fuente y evitar sumas entre escalas no homologadas. Reportar intervalos de incertidumbre cuando el diseño muestral lo permita.
8. Ampliar la encuesta con protocolo de consentimiento, marco muestral, variables demográficas mínimas y análisis separado de telemetría y percepción.
9. Validar el enriquecimiento LLM contra anotaciones humanas y reportar precisión, exhaustividad, F1 y acuerdo entre evaluadores.
10. Ampliar las pruebas con contratos de cada extractor y una regresión de extremo a extremo que compare todos los KPIs para entradas idénticas.

Nota: Las correcciones 1 a 5 fueron solventadas. Las restantes corresponden a validación científica, publicación del snapshot y ampliación del diseño muestral.

6. Conclusiones

1. **La plataforma es funcional como producto de BI descriptivo.** Integra diez fuentes, conserva evidencia Raw, materializa un esquema estrella con seis dimensiones, expone siete vistas KPI y sirve los resultados mediante FastAPI y React.
2. **El Gold vigente representa entidades de origen únicas.** Staging y Gold contienen 127.364 registros, la agrupación por clave estable produce el mismo total y $F = 1,000$. Los 356.945 hechos corresponden a un corte histórico anterior a la corrección y no deben presentarse como estado actual.
3. **Codex domina el corpus, pero no puede afirmarse que domina la población de desarrolladores.** Representa 67,07 % de observaciones y 90,38 % del score de adopción, resultado condicionado por la composición de AIDev.
4. **La identidad y la reproducibilidad técnica fueron corregidas, pero permanece una limitación temporal.** Las fechas ya no son aleatorias y solo 5,45 % son imputadas de forma trazable; sin embargo, AIDev aporta `last_activity` agregada, por lo que la tendencia no equivale a eventos mensuales de adopción.

5. **El proyecto posee potencial para revista o congreso si completa la validación científica.** La ruta pendiente incluye publicar el snapshot y su manifiesto, estratificar KPIs, ampliar la encuesta, validar humanamente el enriquecimiento semántico y separar propietarios de repositorio cuando el análisis de comunidad lo requiera.


Bibliografía

- [1] H. Li, H. Zhang and A. E. Hassan, “AIDev: Studying AI Coding Agents on GitHub,” Zenodo, version 2, Aug. 19, 2025, doi: 10.5281/zenodo.16919051. [Online]. Available: <https://doi.org/10.5281/zenodo.16919051>
- [2] H. Li, H. Zhang and A. E. Hassan, “AIDev: Studying AI Coding Agents on GitHub,” *arXiv preprint arXiv:2602.09185*, 2026. [Online]. Available: <https://arxiv.org/abs/2602.09185>
- [3] S. Peng, E. Kalliamvakou, P. Cihon and M. Demirer, “The Impact of AI on Developer Productivity: Evidence from GitHub Copilot,” *arXiv preprint arXiv:2302.06590*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.06590>
- [4] V. Stray, E. G. Brandtzæg, V. T. Wivestad, A. Barbala and N. B. Moe, “Developer Productivity With and Without GitHub Copilot: A Longitudinal Mixed-Methods Case Study,” *arXiv preprint arXiv:2509.20353*, 2025. [Online]. Available: <https://arxiv.org/abs/2509.20353>
- [5] R. Kimball and M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3rd ed. Indianapolis, IN, USA: Wiley, 2013, ISBN 978-1-118-53080-1.
- [6] Kimball Group, “Four-Step Dimensional Design Process.” [Online]. Available: <https://www.kimballgroup.com/data-warehouse-business-intelligence-resources/kimball-techniques/dimensional-modeling-techniques/four-4-step-design-process/>. Accessed: Jul. 13, 2026.
- [7] Databricks, “What is the medallion lakehouse architecture?” [Online]. Available: <https://docs.databricks.com/aws/en/lakehouse/medallion>. Accessed: Jul. 13, 2026.
- [8] ISO/IEC, *Software Engineering—Software Product Quality Requirements and Evaluation (SQuaRE)—Data Quality Model*, ISO/IEC 25012:2008, confirmed 2025. [Online]. Available: <https://www.iso.org/standard/35736.html>
- [9] M. D. Wilkinson *et al.*, “The FAIR Guiding Principles for scientific data management and stewardship,” *Scientific Data*, vol. 3, Art. no. 160018, 2016, doi: 10.1038/sdata.2016.18.
- [10] P. Groth and L. Moreau, Eds., “PROV-Overview: An Overview of the PROV Family of Documents,” W3C Working Group Note, Apr. 30, 2013. [Online]. Available: <https://www.w3.org/TR/2013/NOTE-prov-overview-20130430/>

- [11] PostgreSQL Global Development Group, “PostgreSQL 16 Documentation: Constraints,” 2026. [Online]. Available: <https://www.postgresql.org/docs/16/ddl-constraints.html>. Accessed: Jul. 13, 2026.
- [12] Stack Exchange, “Stack Exchange API v2.3 Documentation.” [Online]. Available: <https://api.stackexchange.com/docs>. Accessed: Jul. 13, 2026.

A. Modelo lógico y reglas de cálculo

A.1. Relaciones del esquema estrella



La restricción vigente de identidad combina agente, fuente, plataforma e identificador de origen; tiempo, tecnología y comunidad son descriptores del hecho conservado. Para investigación longitudinal se recomienda agregar una dimensión de instantánea y una tabla de hechos periódicos separada, sin convertir la fecha de evento en identidad de la entidad.

A.2. Diccionario de KPIs

KPI	Fórmula/implementación	Uso	Limitación
Adopción por agente	$\text{AVG}(\text{score_adopcion}), \text{SUM}(\text{score_adopcion})$	Comparar señal normalizada por agente	Escala dependiente de fuente
Participación por fuente	$N_s/N \times 100$	Medir composición del corpus	No mide calidad ni representatividad
Tendencia mensual	Agregación por año y mes	Monitoreo temporal	AIDev representa última actividad agregada
Ranking de agentes	Suma de actividad, popularidad, adopción, comunidad e innovación	Priorización operativa	Mezcla escalas heterogéneas
Popularidad abierta	Stars, forks, issues, releases y actividad	Presencia técnica en repositorios	Sesgo hacia GitHub/AIDev

KPI	Fórmula/implementación	Uso	Limitación
Crecimiento mensual	Diferencia y variación con $LAG()$	Cambio respecto al mes previo	No equivale a incidencia mensual de adopción
Distribución por plataforma	$N_p/N \times 100$ y ranking	Entorno de ejecución o integración	79,09 % no determinado
Control de idempotencia	N_{Gold}/N_{K_e}	Detectar snapshots repetidos	$F = 1,000$ en el corte final
Concentración de fuente	$\sum p_s^2$	Dependencia del corpus	Descriptivo, no causal

B. Diccionario de datos Staging/Silver

N.	Campo	Tipo	Definición
1	id	integer	Clave sustituta técnica de Staging.
2	id_origen_registro	text	Identificador estable de la entidad en la fuente o hash SHA-256 de respaldo.
3	fuelle	varchar	Nombre normalizado del origen.
4	tipo_fuente	varchar	API, scraping, archivos o fuente propia.
5	plataforma	varchar	Entorno de ejecución o integración; no representa la fuente de captura.
6	fecha_evento	date	Fecha observada o fecha inmutable de carga Raw cuando falta la primera.
7	nombre_agente	varchar	Agente homologado a uno de 14 valores.
8	categoría	varchar	Actividad técnica, producción, popularidad, comunidad o adopción académica.
9	título	text	Título del artefacto o descripción corta.
10	texto	text	Contenido o resumen normalizado.
11	url	varchar	Enlace de procedencia, máximo 500 caracteres.
12	cantidad_menciones	integer	Conteo homologado de menciones.
13	cantidad_interacciones	integer	Conteo homologado de interacciones.
14	score_popularidad	numeric	Señal relativa de popularidad provista o derivada.
15	stars_github	integer	Estrellas del repositorio.

N.	Campo	Tipo	Definición
16	forks_github	integer	Forks del repositorio.
17	issues_abiertos	integer	Incidencias abiertas.
18	releases	integer	Versiones publicadas cuando la fuente las aporta.
19	indice_adopcion	numeric	Índice de adopción específico por fuente.
20	indice_innovacion	numeric	Índice de innovación específico por fuente.
21	sentimiento_promedio	numeric	Sentimiento agregado cuando está disponible.
22	llm_entorno_uso	varchar	Entorno de uso inferido por LLM.
23	llm_tipo_integracion	varchar	Tipo de integración inferido por LLM.
24	llm_categoria_tecnologia	varchar	Categoría tecnológica inferida.
25	llm_capacidades	text	Capacidades inferidas, separadas por coma.
26	llm_comunidad_tipo	varchar	Tipo de comunidad inferido.
27	llm_confianza	numeric	Confianza declarada por el modelo.
28	fecha_carga	timestamp	Momento de persistencia en Staging.
29	raw_file_id	integer	Clave de procedencia hacia raw.raw_files .
30	is_imputed_date	boolean	Indica que fecha_evento procede de la carga Raw.
31	dim_nombre_plataforma	varchar	Entorno de ejecución o integración derivado.
32	dim_tipo_plataforma	varchar	Tipo de entorno: IDE, CLI, nube, API o web.
33	dim_ecosistema	varchar	Ecosistema tecnológico de la plataforma.
34	dim_plataforma_metodo	varchar	Metadato, regla contextual, regla de agente o sin evidencia.
35	dim_nombre_tecnologia	varchar	Lenguaje, framework, protocolo, herramienta o infraestructura.
36	dim_categoria_tecnologia	varchar	Clase analítica de la tecnología.
37	dim_dominio_tecnologico	varchar	Dominio de aplicación de la tecnología.
38	dim_tipo_senal	varchar	Naturaleza de la señal aportada por la fuente.
39	dim_tecnologia_metodo	varchar	Metadato, regla contextual o sin evidencia.
40	dim_nombre_comunidad	varchar	Propietario, organización, medio o espacio comunitario.

N.	Campo	Tipo	Definición
41	dim_tipo_comunidad	varchar	Tipo de propietario o espacio.
42	dim_region_comunidad	varchar	Región informada; Global cuando no existe detalle.
43	dim_comunidad_metodo	varchar	Metadato estructurado o regla de fuente.

C. Diccionario resumido de la tabla de hechos Gold

Campo/grupo	Tipo	Descripción
id_fact_actividad	bigint	Clave sustituta del hecho.
id_tiempo	bigint/FK	Fecha de la observación.
id_agente	bigint/FK	Agente homologado.
id_fuente	bigint/FK	Fuente de procedencia.
id_plataforma	bigint/FK	Entorno de ejecución o integración.
id_tecnologia	bigint/FK	Tecnología, categoría y dominio tecnológico.
id_comunidad	bigint/FK	Propietario, organización o espacio contextual.
id_origen_registro	text	Identificador estable de procedencia usado en la unicidad.
raw_file_id	integer	Enlace de auditoría al archivo Raw.
cantidad_menciones	integer	Menciones homologadas no negativas.
cantidad_interacciones	integer	Interacciones homologadas no negativas.
score_popularidad	numeric	Popularidad específica por fuente.
score_actividad	numeric	Interacciones más señales técnicas de repositorio.
score_comunidad	numeric	Menciones más interacciones para fuentes comunitarias.
score_adopcion	numeric	Índice de adopción recibido desde Silver.
score_innovacion	numeric	Índice de innovación recibido desde Silver.
valor_numerico_norma lizado	numeric	Primer indicador disponible según precedencia definida.
stars_github, forks_github	integer	Señales de popularidad y reutilización en GitHub.
issues_abiertos, releases	integer	Señales de mantenimiento y publicación.
sentimiento_promedio	numeric	Sentimiento cuando existe.
titulo, url	text/varchar	Contexto legible y enlace de evidencia.
is_imputed_date	boolean	Marca fechas sustituidas por la fecha estable de carga Raw.

Campo/grupo	Tipo	Descripción
fecha_carga	timestamp	Momento de materialización Gold.

D. Artefactos de reproducibilidad del repositorio

- Scripts de creación y carga Gold: `etl/sql/01_create_gold_schema.sql` a `etl/sql/03_load_gold_fact.sql`.
- Vistas y consultas: `etl/sql/04_create_kpi_views.sql` y `etl/sql/05_consultas_analiticas_e4.sql`.
- Validación: `etl/sql/06_validacion_gold_dw.sql`.
- Migración semántica e identidad estable: `etl/sql/07_add_semantic_staging_columns.sql`.
- Evidencias: `etl/docs/evidencias/quality_summary.csv`, `dedup_report.csv`, `nulls_matrix.csv`, `casting_report.csv` y archivos `e4_respuesta_*.csv`.
- Respaldo físico: `dump_gold_entregable4.sql`.
- Código ETL: `etl/src/`; API: `backend/`; dashboard: `frontend/`.
- Pruebas automatizadas: `etl/tests/test_dates.py`, `test_dedup.py` y `test_semantic_dimensions.py` (12 casos).